

SVEUČILIŠTE U MOSTARU
FAKULTET PRIRODOSLOVNO-MATEMATIČKIH I ODGOJNIH ZNANOSTI

Podatkovna znanost i inženjerstvo

**Klasifikacija kibernetičkih napada primjenom algoritma
strojnog učenja**

Stana Ćavar

Mostar, 2026. godine

SADRŽAJ

SAŽETAK.....	3
UVOD	4
RELATED WORK.....	5
PODATCI.....	6
Izvor podataka.....	6
Opis dataseta	6
Struktura podataka	6
Statistički pregled numeričkih obilježja.....	7
METODOLOGIJA.....	8
Predobrada podataka	8
Inženjerstvo obilježja	8
Podjela podataka	9
Modeli strojnog učenja.....	9
EKSPERIMENTI.....	10
Opis eksperimenata	10
Evaluacijske metrike	10
REZULTATI.....	12
Usporedba točnosti modela.....	12
Detaljni rezultati po klasama.....	12
Važnost obilježja	13
Grafovi i vizualizacije	14
Rasprava.....	15
Interpretacija rezultata.....	15
Uzroci slabih rezultata	15
Prednosti primijenjenog pristupa	16
Ograničenja	16
Zaključak.....	17
LITERATURA	18

SAŽETAK

Ovaj rad istražuje mogućnost automatske klasifikacije kibernetičkih napada korištenjem algoritama strojnog učenja. Analiziran je skup podataka od 40.000 mrežnih događaja koji sadrži obilježja mrežnog prometa poput protokola, duljine paketa, anomaly scorea i raznih sigurnosnih indikatora. Napadi su podijeljeni u tri kategorije: DDoS, Intrusion i Malware. Primijenjeni su algoritmi Stabla odlučivanja (Decision Tree), Nasumičnih šuma (Random Forest) i Logističke regresije (Logistic Regression). Rezultati pokazuju da sva tri modela postižu točnost oko 33–35%, što odgovara razini slučajnog pogađanja na uravnoteženom skupu podataka s tri klase. Ovo ukazuje na ograničenu diskriminativnu moć dostupnih obilježja i otvara prostor za buduća istraživanja s naprednijim metodama ekstrakcije obilježja.

UVOD

Kibernetička sigurnost jedan je od najbrže rastućih izazova suvremenog digitalnog društva. Svakodnevno se bilježe milijuni pokušaja neovlaštenog pristupa mrežama, distribuiranih napada uskraćivanjem usluge (DDoS) te infekcija zlonamjnim softverom. Tradicionalni pristupi detekciji napada, poput ručnog pregledavanja logova ili statičkih pravila u vatrozidima, ne mogu pratiti brzinu i raznovrsnost modernih prijetnji.

Strojno učenje nudi obećavajući pristup automatizaciji detekcije i klasifikacije napada. Umjesto ručnog definiranja pravila, modeli uče iz podataka i sposobni su prepoznati uzorke koji nisu unaprijed poznati analitičarima.

Cilj ovog projekta je izgradnja i evaluacija modela strojnog učenja koji automatski klasificira mrežne događaje u tri kategorije kibernetičkih napada: DDoS (Distributed Denial of Service), Intrusion (neovlašteni upad) i Malware (zlonamjni softver). Pritom se koristi javno dostupan skup podataka koji simulira realne mrežne uvjete s relevantnim obilježjima.

Specifični ciljevi projekta su:

- Provesti predobradu i čišćenje podataka
- Izgraditi i usporediti tri klasifikacijska modela
- Evaluirati modele standardnim metrikama (točnost, preciznost, odziv, F1-mjera)
- Interpretirati rezultate i identificirati ograničenja pristupa

RELATED WORK

Istraživanja primjene strojnog učenja u detekciji kibernetičkih napada brojna su i raznovrsna. Ovaj odjeljak daje pregled najrelevantnijih radova koji se bave klasifikacijom DDoS napada, upada (intrusion) i zlonamjernog softvera.

Distribuirani napadi uskraćivanjem usluge (DDoS) postali su kritičan problem u kibernetičkoj sigurnosti. Istraživači su predložili okvir EDAD koji koristi PCA za odabir obilježja, a za klasifikaciju koristi algoritme SVM, Logistic Regression, Random Forest, KNN i Decision Tree [4].

Na skupu podataka UNSW-NB15 uspoređeni su Logistic Regression, SVM, Decision Tree i Random Forest. Rezultati i confusion matrice pokazali su da je Random Forest najbolji izbor za identifikaciju kibernetičkih napada, s najboljim F1-rezultatom od svih ispitanih modela [5].

Istraživanje koje je evaluiralo Linear Regression, Logistic Regression, SVM, KNN, Random Forest, Decision Tree i MLP na skupu UNSW-NB15 otkrilo je da većina klasifikatora koristi manje od tri kritična obilježja za postizanje točnosti od 90%, što ukazuje da učinkovito inženjerstvo obilježja može biti važnije od složenosti modela. Random Forest pokazao se najboljim po točnosti, vremenskoj učinkovitosti i robustnosti [8].

Sustavna analiza nadziranih algoritama za detekciju upada s fokusom na Logistic Regression zaključuje da Random Forest tipično postiže više stope detekcije u usporedbi s Logistic Regression, ali uz manji stupanj interpretabilnosti modela [6].

Za detekciju DDoS napada korištenjem skupova CICDDoS2019, UNSW-NB15 i NSL-KDD predložen je model koji kombinira neuronske mreže, naivni Bayes, SVM i ensemble metode, postižući točnost od 96–99% no autori napominju da optimalni skup obilježja i tehnika i dalje nije utvrđen [2].

Poseban izazov u ovom području predstavlja ovisnost modela strojnog učenja o visokokvalitetnim i reprezentativnim podacima. Istraživanja pokazuju da sintetički skupovi podataka često ne zadovoljavaju zahtjeve stvarnih scenarija jer imaju smanjenu vjernost vremenskih uzoraka, raznovrsnost sadržaja paketa i pokrivenost scenarija napada [9].

PODATCI

Izvor podataka

Skup podataka korišten u ovom radu je javno dostupan sintetički dataset pod nazivom Cybersecurity Attacks Dataset, dostupan na platformi Kaggle. Dataset simulira realne mrežne uvjete i namijenjen je istraživanjima u području detekcije i klasifikacije kibernetičkih napada primjenom algoritama strojnog učenja.

Opis dataseta

Dataset sadrži 40.000 redaka i 25 stupaca. Svaki redak predstavlja jedan mrežni događaj, a stupci opisuju njegova obilježja. Klase su gotovo savršeno uravnotežene, što eliminira potrebu za tehnikama balansiranja poput SMOTE-a:

	count
Attack Type	
DDoS	13428
Malware	13307
Intrusion	13265

dtype: int64

Struktura podataka

Dataset sadrži numerička, kategorička i tekstualna obilježja:

	0
Source Port	int64
Destination Port	int64
Protocol	object
Packet Length	int64
Packet Type	object

	0
Traffic Type	object
Malware Indicators	object
Anomaly Scores	float64
Alerts/Warnings	object
Attack Type	object
Attack Signature	object
Action Taken	object
Severity Level	object
Network Segment	object
Firewall Logs	object
IDS/IPS Alerts	object
Log Source	object

dtype: object

Stupci Payload Data, User Information, Device Information, Proxy Information i Geo-location Data sadrže nasumično generirane vrijednosti bez prediktivne vrijednosti te su uklonjeni u fazi predobrade.

Statistički pregled numeričkih obilježja

Četiri numerička obilježja koja nose najveću prediktivnu težinu su:

	Source Port	Destination Port	Packet Length	Anomaly Scores
count	40000.000000	40000.000000	40000.000000	40000.000000
mean	32970.356450	33150.868650	781.452725	50.113473
std	18560.425604	18574.668842	416.044192	28.853598
min	1027.000000	1024.000000	64.000000	0.000000
25%	16850.750000	17094.750000	420.000000	25.150000
50%	32856.000000	33004.500000	782.000000	50.345000
75%	48928.250000	49287.000000	1143.000000	75.030000
max	65530.000000	65535.000000	1500.000000	100.000000

METODOLOGIJA

Predobrada podataka

Prije primjene algoritama strojnog učenja, provedena je temeljita predobrada podataka kako bi se uklonili irelevantni stupci, ispravile nedostajuće vrijednosti te podaci doveli u oblik pogodan za treniranje modela.

U prvom koraku uklonjeno je osam stupaca koji ne doprinose klasifikaciji. Radi se o stupcima koji sadrže jedinstvene identifikatore mrežnih uređaja poput IP adresa izvora i odredišta, vremenskih oznaka, sadržaja paketa te korisničkih i uređajnih informacija. Budući da svaki mrežni događaj ima jedinstvenu IP adresu i vremensku oznaku, ti stupci nemaju prediktivnu vrijednost za klasifikacijski model te bi njihovim zadržavanjem model naučio prepoznavati pojedinačne događaje umjesto općih uzoraka napada.

Nakon uklanjanja stupaca utvrđeno je da četiri preostala stupca imaju značajan udio nedostajućih vrijednosti, otprilike polovica redaka nije imala unos za stupce koji bilježe indikatore zlonamjernog softvera, upozorenja, zapise vatrozida te upozorenja sustava za detekciju upada. Budući da odsutnost tih informacija i sama po sebi nosi značenje, nedostajuće vrijednosti nisu uklonjene nego su popunjene odgovarajućim zadanim vrijednostima koje označavaju izostanak detekcije. Provjera dupliciranih redaka pokazala je da u datasetu nema dupliciranih unosa.

Inženjerstvo obilježja

Nakon predobrade, provedeno je inženjerstvo obilježja s ciljem pretvaranja svih podataka u numerički format koji algoritmi strojnog učenja mogu obraditi.

Ciljna varijabla Attack Type kodirana je numerički pri čemu je klasa DDoS dobila oznaku 0, Intrusion oznaku 1, a Malware oznaku 2. Kategorička obilježja kao što su protokol, vrsta paketa i vrsta prometa pretvorena su u numerički format primjenom metode One-Hot Encodinga. Ovom metodom svaka jedinstvena vrijednost kategoričkog stupca postaje zaseban binarni stupac, čime se izbjegava nametanje lažnog redosljeda između kategorija. Kako bi se izbjegla multikolinearnost, jedna od kategorija za svaki stupac izostavljena je iz skupa obilježja. Nakon transformacije, skup obilježja

proširen je na veći broj binarnih stupaca. Konzistentnost između skupa za treniranje i testiranje osigurana je poravnavanjem stupaca testnog skupa prema stupcima skupa za treniranje.

Podjela podataka

Podaci su podijeljeni u omjeru 80% za treniranje i 20% za testiranje, pri čemu je skup za treniranje sadržavao 32.000 primjera, a skup za testiranje 8.000 primjera. Podjela je provedena uz stratifikaciju prema ciljnoj varijabli kako bi se osigurala proporcionalna zastupljenost svake klase u oba skupa.

Modeli strojnog učenja

U radu su primijenjena tri klasifikacijska algoritma koji su međusobno uspoređeni.

Stablo odlučivanja je algoritam koji gradi hijerarhijsku strukturu pravila na temelju koje klasificira nove primjere. Prednost ovog algoritma je visoka interpretabilnost jer je moguće točno pratiti zašto je model donio određenu odluku. Nedostatak je sklonost preprilagođavanju skupu za treniranje, posebno kada se ne ograničava dubina stabla.

Nasumična šuma je napredna ensemble metoda koja kombinira veći broj stabala odlučivanja treniranih na različitim podskupovima podataka i obilježja. Konačna klasifikacija određuje se glasanjem svih stabala, što povećava robustnost modela i smanjuje varijancu u odnosu na pojedinačno stablo. U ovom radu korišteno je 100 stabala.

Logistička regresija je linearni model koji procjenjuje vjerojatnost pripadnosti pojedinoj klasi. Budući da je osjetljiva na razlike u skalama numeričkih obilježja, prije treniranja provedena je standardizacija podataka kojom su sve vrijednosti svedene na isti raspon. Model je treniran s povećanim maksimalnim brojem iteracija kako bi se osigurala konvergencija optimizacijskog algoritma.

EKSPERIMENTI

Opis eksperimenata

U sklopu ovog rada provedeni su eksperimenti klasifikacije mrežnih događaja u tri kategorije kibernetičkih napada. Cilj eksperimenata bio je utvrditi koji od tri odabrana algoritma strojnog učenja postiže najbolje rezultate na zadanom skupu podataka te identificirati eventualna ograničenja koja utječu na kvalitetu klasifikacije.

Svi eksperimenti provedeni su u programskom jeziku Python unutar razvojnog okruženja Jupyter Notebook, korištenjem biblioteke scikit-learn za implementaciju modela strojnog učenja te biblioteka pandas i numpy za manipulaciju podacima. Kako bi rezultati bili reproducibilni, svim algoritmima postavljen je isti parametar slučajnosti (`random_state=42`).

Svaki od tri modela treniran je na istom skupu za treniranje i evaluiran na istom skupu za testiranje, čime je osigurana objektivna usporedba. Za logističku regresiju podaci su dodatno standardizirani prije treniranja, što je nužno zbog osjetljivosti tog algoritma na razlike u skalama obilježja.

Evaluacijske metrike

Za evaluaciju performansi modela korištene su četiri standardne metrike klasifikacije.

Točnost (Accuracy) predstavlja udio ispravno klasificiranih primjera u ukupnom broju primjera. Budući da su klase u ovom datasetu uravnotežene, točnost je pouzdana mjera ukupne uspješnosti modela.

Preciznost (Precision) mjeri koliki udio primjera koje je model svrstao u određenu klasu zaista pripada toj klasi. Visoka preciznost znači da model rijetko pogrešno klasificira primjere koji ne pripadaju nekoj klasi kao da joj pripadaju.

Odziv (Recall) mjeri koliki udio stvarnih primjera neke klase je model ispravno prepoznao. Visok odziv znači da model propušta mali broj stvarnih napada određene vrste.

F1-mjera (F1-score) predstavlja harmonijsku sredinu preciznosti i odziva te daje uravnoteženu sliku performansi modela, posebno korisnu kada je važno uzeti u obzir i lažno pozitivne i lažno negativne klasifikacije.

Osim navedenih metrika, za svaki model prikazana je matrica zabune (Confusion Matrix) koja pokazuje točan raspored ispravnih i pogrešnih klasifikacija po pojedinim klasama, omogućujući detaljniju analizu gdje model griješi.

REZULTATI

Usporedba točnosti modela

Nakon provedenih eksperimenata, izmjerena je točnost sva tri modela na testnom skupu od 8.000 primjera. Rezultati su prikazani u sljedećoj tablici:

	Model	Accuracy
2	Logistic Regression	0.3476
1	Random Forest	0.3295
0	Decision Tree	0.3265

Logistička regresija postigla je najvišu točnost od 34,76%, što je tek neznatno iznad razine slučajnog pogađanja od 33,33% koja se očekuje na savršeno uravnoteženom skupu s tri klase. Nasumična šuma i stablo odlučivanja postigli su gotovo identične rezultate, 32,95% i 32,65%.

Detaljni rezultati po klasama

=====

DECISION TREE

Accuracy: 0.3265

	precision	recall	f1-score	support
DDoS	0.33	0.32	0.33	2686
Intrusion	0.32	0.33	0.32	2653
Malware	0.33	0.33	0.33	2661
accuracy			0.33	8000
macro avg	0.33	0.33	0.33	8000
weighted avg	0.33	0.33	0.33	8000

=====

RANDOM FOREST

Accuracy: 0.3295

	precision	recall	f1-score	support
DDoS	0.33	0.35	0.34	2686
Intrusion	0.34	0.33	0.33	2653
Malware	0.32	0.31	0.31	2661
accuracy			0.33	8000
macro avg	0.33	0.33	0.33	8000
weighted avg	0.33	0.33	0.33	8000


LOGISTIC REGRESSION

Accuracy: 0.3476

	precision	recall	f1-score	support
DDoS	0.36	0.41	0.38	2686
Intrusion	0.34	0.28	0.31	2653
Malware	0.35	0.35	0.35	2661
accuracy		0.35		8000
macro avg	0.35	0.35	0.35	8000
weighted avg	0.35	0.35	0.35	8000

Važnost obilježja

Analiza važnosti obilježja metodom nasumične šume pokazala je da četiri numerička obilježja nose gotovo jednaku i dominantnu prediktivnu težinu.




Ta četiri obilježja zajedno čine oko 63% ukupne prediktivne snage modela. Preostalih 37% raspoređeno je na binarna obilježja nastala One-Hot Encodingom, od kojih nijedno pojedinačno ne prelazi 3% važnosti.


Grafovi i vizualizacije

U sklopu projekta generirani su sljedeći grafovi koji su priloženi uz ovaj izvještaj:

- Graf distribucije klasa - prikazuje uravnoteženu zastupljenost sve tri klase napada u datasetu
- Matrice zabune - za svaki model prikazuju raspored ispravnih i pogrešnih klasifikacija po klasama



Slika 1: Distribucija vrsta napada



Slika 2: Matrice zabune

Rasprava

Interpretacija rezultata

Rezultati eksperimenata pokazuju da sva tri primijenjena modela postižu točnost koja se kreće između 32,65% i 34,76%, što je gotovo jednako razini slučajnog pogađanja od 33,33% koja se očekuje na savršeno uravnoteženom skupu podataka s tri klase. Ovakvi rezultati ukazuju da modeli nisu uspjeli pronaći smislene uzorke u podacima koji bi omogućili pouzdanu klasifikaciju vrsta napada.

Logistička regresija postigla je blago bolju točnost od preostala dva modela, što je donekle iznenađujuće s obzirom da je to linearni model koji se u literaturi uglavnom smatra manje moćnim od ensemble metoda poput nasumične šume [6]. Nasumična šuma i stablo odlučivanja postigli su gotovo identične rezultate, što sugerira da povećanje broja stabala u ovom slučaju nije donijelo značajno poboljšanje.

Analiza matrica zabune otkriva da niti jedan model nije razvio preferenciju prema određenoj klasi, pogreške su gotovo ravnomjerno raspoređene između sve tri klase. To znači da modeli nisu naučili čak niti grubo razlikovati vrste napada, nego se njihove odluke svode na nasumično raspoređivanje primjera.

Uzroci slabih rezultata

Glavni uzrok slabih rezultata leži u prirodi samog dataseta. Radi se o sintetički generiranom skupu podataka u kojemu su vrijednosti obilježja nasumično generirane, a klase napada dodijeljene bez stvarne veze s obilježjima mrežnog prometa. U takvim uvjetima ne postoji obrazac koji bi model mogao naučiti, bez obzira na složenost algoritma.

Analiza važnosti obilježja nasumične šume pokazala je da četiri numerička obilježja: Source Port, Destination Port, Anomaly Scores i Packet Length nose gotovo jednaku prediktivnu težinu od oko 15-16% svako. Činjenica da su ova obilježja gotovo jednako važna i da zajedno čine 63% ukupne prediktivne snage, a pri tome model i dalje postiže samo 33% točnosti, dodatno potvrđuje da ni ta obilježja ne sadrže dovoljno informacija za pouzdanu klasifikaciju.

Dodatni uzrok je uklanjanje stupaca koji bi potencijalno mogli sadržavati korisne informacije, poput sadržaja paketa i vremenskih oznaka. Međutim, budući da su i te vrijednosti nasumično generirane u ovom datasetu, njihovo zadržavanje vjerojatno ne bi značajno poboljšalo rezultate.

Prednosti primijenjenog pristupa

Unatoč slabim rezultatima klasifikacije, primijenjeni pristup ima nekoliko važnih prednosti. Postupak predobrade podataka proveden je ispravno i sustavno, a podjela na skup za treniranje i testiranje uz uravnoteženu podjelu podataka po klasama osigurana je objektivna evaluacija svih modela. Usporedba triju različitih algoritama omogućila je stjecanje uvida u njihove relativne prednosti i nedostatke na ovoj vrsti podataka.

Ograničenja

Glavno ograničenje ovog istraživanja je korištenje sintetičkog dataseta čije vrijednosti ne odražavaju stvarne odnose između mrežnih obilježja i vrsta napada. Na realnim mrežnim podacima, poput skupova NSL-KDD ili UNSW-NB15 koji se koriste u literaturi [5][8], isti algoritmi postižu točnosti između 90% i 99%. Ovo jasno pokazuje da kvaliteta i reprezentativnost podataka imaju presudan utjecaj na performanse modela strojnog učenja.

Zaključak

U ovom radu istražena je primjena algoritama strojnog učenja za automatsku klasifikaciju kibernetičkih napada. Na skupu podataka od 40.000 mrežnih događaja primijenjeni su algoritmi stabla odlučivanja, nasumične šume i logističke regresije s ciljem klasifikacije napada u tri kategorije: DDoS, Intrusion i Malware.

Rezultati eksperimenata pokazali su da sva tri modela postižu točnost koja se kreće oko 33%, što odgovara razini slučajnog pogađanja na uravnoteženom skupu s tri klase. Logistička regresija postigla je blago najvišu točnost od 34,76%, dok su nasumična šuma i stablo odlučivanja postigli 32,95% i 32,65%. Analiza važnosti obilježja pokazala je da četiri numerička obilježja: Source Port, Destination Port, Anomaly Scores i Packet Length nose dominantnu prediktivnu težinu, no ni ona nisu bila dovoljna za pouzdanu klasifikaciju.

Temeljni uzrok ovakvih rezultata identificiran je u prirodi korištenog dataseta. Budući da se radi o sintetički generiranom skupu podataka u kojemu su vrijednosti nasumično generirane bez stvarne veze s klasama napada, modeli nisu imali mogućnost naučiti smislene uzorke. Ovo je potvrđeno usporedbom s rezultatima iz literature gdje isti algoritmi na realnim mrežnim skupovima podataka postižu točnosti između 90% i 99% [5][8].

Za buduća istraživanja preporučuje se primjena na realnim skupovima podataka poput NSL-KDD, UNSW-NB15 ili CICDDoS2019 koji sadrže autentične veze između mrežnih obilježja i vrsta napada [3]. Dodatno, naprednije metode ekstrakcije obilježja, primjena naprednijih algoritama poput dubokih neuronskih mreža [2] te istraživanje tehnika objašnjivog umjetnog uma mogli bi značajno poboljšati rezultate klasifikacije [8].

LITERATURA

- [1] Najafimehr, M., Zarifzadeh, S., Mostafavi, S. (2023). DDoS attacks and machine-learning-based detection methods: A survey and taxonomy. Engineering Reports. Dostupno na: <https://onlinelibrary.wiley.com/doi/epdf/10.1002/eng2.12697>
- [2] Patidar, S., Singh, S., Malik, A. (2026). *A Machine Learning-Based Automated DDoS Malware Attack Detection Scheme*. National Academy Science Letters, Springer Nature. Dostupno na: <https://link.springer.com/article/10.1007/s40009-026-02133-7>
- [3] Sadhwani, S., Manibalan, B., Muthalagu, R., Pawar, P. (2023). *A Lightweight Model for DDoS Attack Detection Using Machine Learning Techniques*. Applied Sciences, 13(17), 9937. MDPI. Dostupno na: <https://www.mdpi.com/2076-3417/13/17/9937>
- [4] Abiramasundari, S., Ramaswamy, V. (2025). *Distributed denial-of-service (DDoS) attack detection using supervised machine learning algorithms*. Scientific Reports, Nature. Dostupno na: <https://www.nature.com/articles/s41598-024-84879-y>
- [5] More, S., Idrissi, M., Mahmoud, H., Asyhari, A.T. (2024). *Enhanced Intrusion Detection Systems Performance with Feature Selection*. Algorithms, 17, 64. Birmingham City University. Dostupno na: <https://www.open-access.bcu.ac.uk/15332/1/algorithms-17-00064.pdf>
- [6] Graham, O., Lloris, J. (2025). *Comparative Study of Supervised Learning Algorithms for Intrusion Detection with a Focus on Logistic Regression*. Preprints.org. Dostupno na: <https://www.preprints.org/manuscript/202505.0420>
- [7] Chen, Z., Yu, W., Zhou, L. (2021). *ADASYN-Random Forest Based Intrusion Detection Model*. arXiv:2105.04301. Dostupno na: <https://arxiv.org/pdf/2105.04301>
- [8] Corea, P.M., Liu, Y., Wang, J., Niu, S., Song, H. (2024). *Explainable AI for Comparative Analysis of Intrusion Detection Models*. arXiv:2406.09684. Dostupno na: <https://arxiv.org/pdf/2406.09684>
- [9] Li, J., Ersotelos, N., Tsompanas, M., Epiphaniou, G. (2026). *Challenges and Opportunities of Synthetic Data Generation for ML-based Intrusion Detection Systems*. Computers & Security, ScienceDirect. Dostupno na: <https://www.sciencedirect.com/science/article/pii/S2214209625001251>